

# KNSI Golem Bootcamp 2023

Spotkanie 1

# Agenda

- W skrócie o nas
- Co można z nami robić
- Omówienie bootcampu
- Wprowadzenie do ML (Prezka)
- Wprowadzenie do przetwarzania danych pod ML (Google Colab)

## Kluczowe informacje

- Istniejemy od 2017r.
- Wydział EiTI
- opiekun koła: dr hab. inż. Jarosław Arabas
- Zarząd na ten rok akademicki:
  - Jakub Sobolewski (prezes)
  - Weronika Piotrowska (vice)
  - Piotr Kitłowski (skarbnik)
- Własny komputer obliczeniowy w ZSI (4xGeForce RTX 2070 Super)



# Nasza misja/cele/wartości

- Dążymy do zwiększania poziomu wiedzy członków koła
- Jesteśmy otwarci na ludzi, którzy chcą z nami działać
- Tworzymy społeczność ludzi zainteresowanych AI/ML

# Aktywności koła

Hackathony




Projekty



Prelekcje + Piwo



Bootcamp



Roadmap, czyli jak zostać Golemem

# 1. Bootcamp

Jeśli tu jesteś, to dopiero początek Twojej drogi :)

## Bootcamp #1

### Wstęp

Jakub Sobolewski

---

30 października 2023

WEiTl, sala 161

18:00



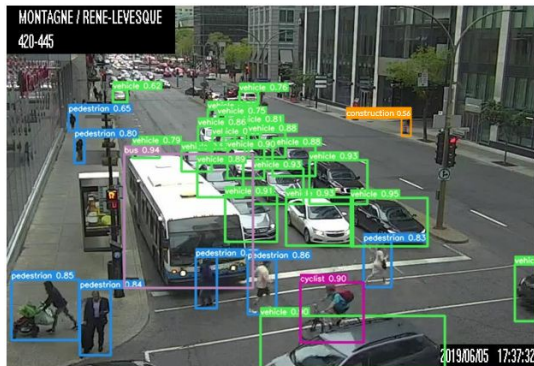
## 2. Bootcamp Level-Up

- Termin: następny semestr
- Cel: dostarczyć podstawową wiedzę i umiejętności z najpopularniejszych dziedzin Deep Learningu
- Must have by móc wejść głębiej w inne zagadnienia AI
- Bardziej zaawansowane tematy i zagadnienia




## 2. Bootcamp Level-Up → Tematy


# Computer Vision



## NLP



# Reinforcement Learning



# Unsupervised Learning

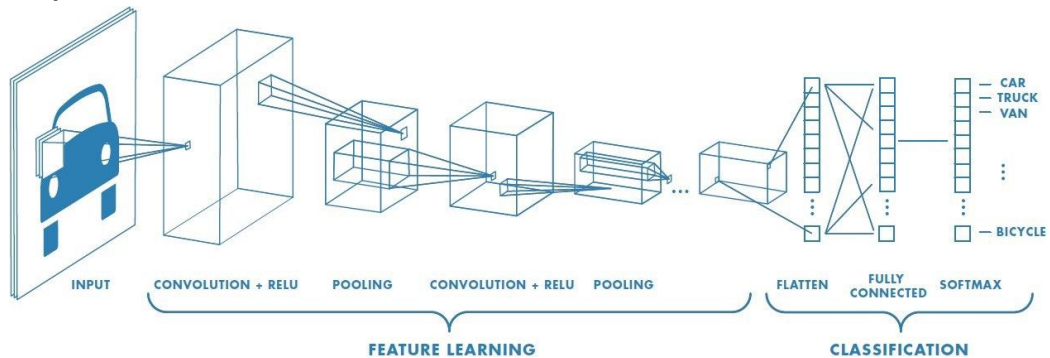


### 3. Study Groups

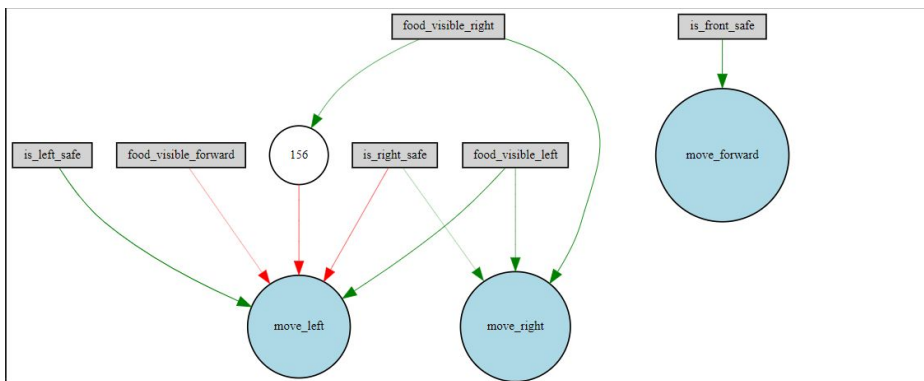
- Dedykowane konkretnej dziedzinie/zagadnieniu
- Nastawione na wzajemną naukę
- Docelowo mają wyłaniać się z nich projekty Koła :)
- kanał #study-groups
- świetna okazja by wkręcić się jeszcze głębiej w AI

# 3. Study Groups


## Computer Vision SG



## Beginner SG




## Generative models SG




## Continual Learning SG

### Static ML



### Adaptive ML



# Pudzian



## 4. Hackathony - świetna zabawa

Byliśmy na

- BiteHack 2022 w Krakowie (1. i 3. miejsce w kategorii AI)
- BrainHack Warsaw
- CuValley Hackathon
- Best Hacking League
- KNUM x Golem Hackathon 2022 (2. miejsce w kategorii AI)
- AI Games 2022 w Gdańsku (aż 25 osób 1,2,3 miejsce)
- Space Apps NASA (18 osób)

Coming soon

- Ensemble AI hackathon (wiosną)
- wiele więcej!

Będzie więcej ;) (i to za hajs polibudy!)

## 5. Prelekcje

- Prawie każdy czwartek o 18:15
- zaproszony gość przedstawia jakiś temat związany z ML
  - badania naukowe
  - ciekawe algorytmy
  - zastosowania

# Zakład Sztucznej Inteligencji & CV Lab


- Projekty badawcze
- Specjaliści i mentorzy
- Ciekawe i zaawansowane tematy
- Spin-off
- Co jest potrzebne:
  - skille zdobyte w poprzednich punktach
  - chęci
  - czas

**A przede wszystkim potrzebny  
jest zespół**




# Co się dzieje w ZSI & CV Lab?


## Continual Learning



## Multitask Learning




(a)



(b)

## Reinforcement Learning





I wiele innych...

# Bootcamp – struktura

## 1. 5 spotkań:

- a. Wstęp (Jakub)
- b. Regresja (Weronika)
- c. Klasyfikacja (Antoni)
- d. Sztuczne Sieci Neuronowe (Maciek)
- e. Konwolucyjne Sieci Neuronowe (Janek)

## 2. W ramach każdego spotkania:

- a. Wykład, prezentacja + przykłady w kodzie
- b. Praca domowa wraz z rozwiązaniami

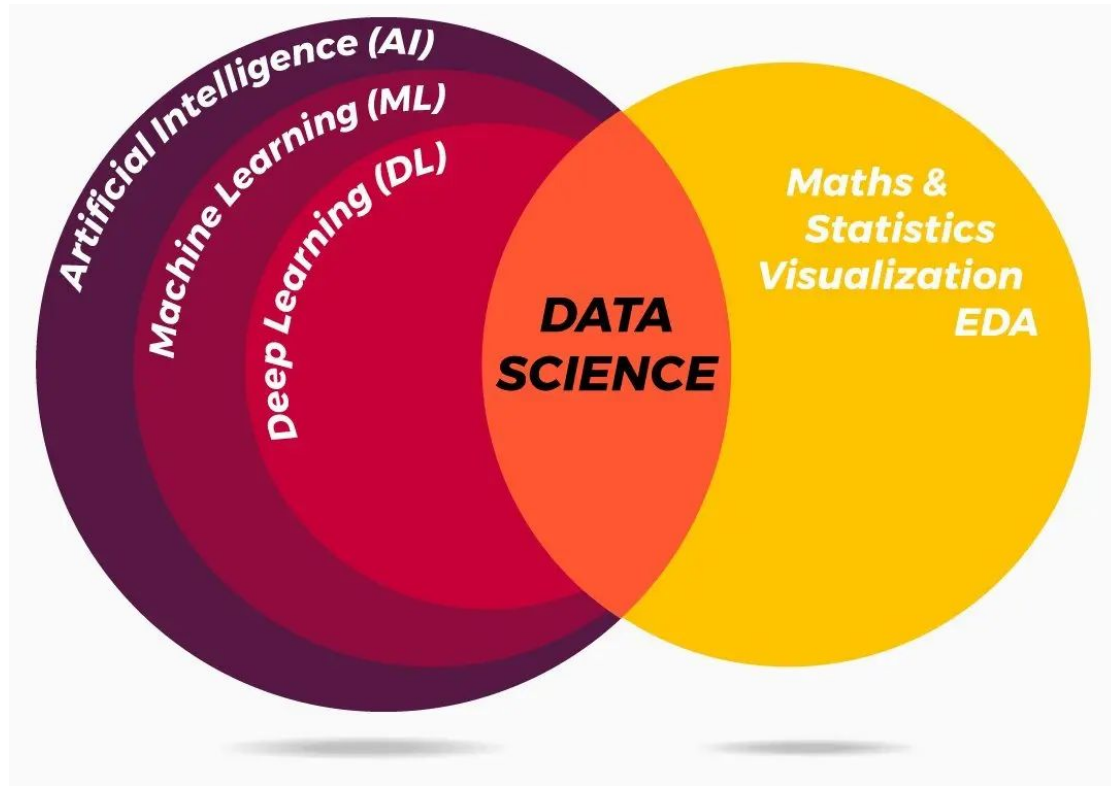
Q&A

# Część druga

# Agenda po raz drugi

- AI ML DL
- Dane, dane, dane – kluczowe koncepty
- Typy zmiennych
- Jak rozumieć Machine Learning?
- Czym jest predykcja?
- Podstawowe zadania
- Metody uczenia się
- Pułapki uczenia się
- Podsumowanie
- Część trzecia ;)

# AI, ML, DL?





O danych słów kilka

# Kluczowe koncepty

- Zbiory:
  - treningowy
  - testowy
- Zbiór cech (tzw. features)
- Cel predykcji (target, label)
- Dwuwymiarowe tabelki (przynajmniej na razie)
- Typy cech:
  - ciągłe
  - dyskretne (kategoryczne)



# Dataset

**Cechy**

**Cel**

**Wymiar cech**

**Wymiar rekordów (wiersze)**

	categorical_feature_1	categorical_feature_2	categorical_feature_3	categorical_feature_4	continuous_feature_1	continuous_feature_2	target
0	f	d	h	g	335.699617	145.288619	0
1	b	h	e	e	101.786116	10.796348	1
2	f	g	h	f	251.530238	205.116568	0
3	h	h	c	f	42.022427	28.089197	0
4	c	e	g	h	114.155232	12.432317	1

# Machine Learning (Maszynowe Uczenie się)

# Jak to rozumieć?

## Maszynowe


- Bez tzw. 'ifologii'
- Oparte na danych
- Celem: parametryzowany model rozwiązujący pewne, wysoce wyspecjalizowane zadanie (np. rozpoznawanie czy dany zbiór pikseli reprezentuje literę G)

## Uczenie się

- Inspirowane sposobem, w jaki uczy się człowiek
- Mechanizm: pętla sprzężenia zwrotnego
- Kluczem: dane

# Model

## Algorytm uczący



## Parametry

$$\begin{matrix} & \begin{matrix} 1 & 2 & \dots & n \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ \vdots \\ m \end{matrix} & \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ a_{31} & a_{32} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix} \end{matrix}$$

## Funkcja straty

$$\text{MSE}(\mathcal{D}, f) := \frac{1}{n} \sum_{i=1}^n \|\mathbf{y}_i - f(\mathbf{x}_i)\|_2^2,$$

# Trening

Zbiór treningowy

	categorical feature 1	categorical feature 2	categorical feature 3	categorical feature 4	continuous feature 1	continuous feature 2	target
0	e	c	c	e	118.633799	152.453576	0
1	e	e	h	c	204.479752	135.259612	1
2	h	g	e	f	99.076089	25.263754	0
3	e	a	b	a	20.543345	263.686608	1
4	a	c	c	e	137.473731	190.692092	1
5	b	d	c	h	53.853686	42.772230	1
6	f	c	c	a	176.981080	148.681766	0
7	b	b	e	e	167.223956	41.521861	0
8	e	e	e	f	219.476611	276.671168	1
9	a	b	g	f	200.718175	174.592773	1
10	a	g	b	b	116.951042	66.945875	1
11	d	h	f	d	75.236034	19.340713	0
12	c	f	b	e	32.082324	169.998350	1
13	h	c	a	h	55.152452	271.143753	1
14	g	g	e	c	151.868236	91.840448	0
15	b	g	f	e	78.591005	305.604886	0
16	g	a	c	g	159.383117	236.990436	1
17	h	b	g	d	33.673526	164.716809	1
18	a	e	g	d	200.276430	325.659930	0
19	c	e	b	c	211.581914	175.281508	0

Aktualizacja parametrów modelu

$$\begin{matrix}
 & 1 & 2 & \dots & n \\
 \begin{matrix} 1 \\ 2 \\ 3 \\ \vdots \\ m \end{matrix} & \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ a_{31} & a_{32} & \dots & a_{3n} \\ \vdots & \vdots & \vdots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}
 \end{matrix}$$

Predykcja

$$\text{MSE}(\mathcal{D}, f) := \frac{1}{n} \sum_{i=1}^n \|\mathbf{y}_i - f(\mathbf{x}_i)\|_2^2,$$


Błąd / Strata



# Typy zadań predykcyjnych (podstawowe)


## Regresja (spotkanie 2.)

- Przewidywanie ciągłej wartości
- Przykład: jaka powinna być wartość nieruchomości bazując na danych o niej?
- Podstawowy model: regresja liniowa



## Klasyfikacja (spotkanie 3.)

- Przewidywanie klasy/kategorii
- Przykład: jaki gatunek piwa powstanie mając dane nt procesu jego wytwarzania?
- Podstawowy model: drzewo decyzyjne, regresja logistyczna (tak, to coś innego)



# Typy uczenia się

## Nadzorowane (supervised)

- W zbiorze treningowym znana jest nam wartość, którą chcemy przewidywać
- Naszym zadaniem jest przewidzenie jej w zbiorze testowym (ewaluacyjnym)
- Bootcamp dotyczy praktycznie tylko takiego typu uczenia się

## Nienadzorowane (unsupervised)

- Zazwyczaj dotyczy klastryzacji
- Przykład: mając 100 punktów danych o zachowaniu użytkowników w serwisie znajdź ukryte podgrupy
- (Jeśli działa) umożliwia odkrywanie ukrytych zależności w dużych i wielowymiarowych zbiorach danych

Mniej przyjemna rzeczywistość




# Co może pójść nie tak?


## Overfitting

## Underfitting

Underfitting



Overfitting



# Podsumowanie

- KNSI Golem jest fajne i robi fajne rzeczy, róbcie je z nami :)
- Od zera do Golema
- Struktura bootcampu
- Dane
- Kluczowe koncepty: Maszynowe Uczenie się
- Z czego składa się model ML?
- Jak wygląda jego trening?
- Typy zadań oraz uczenia się
- Na co trzeba uważać?

Q&A

Krótki przykład podstawowych bibliotek

